

חיזוי מיקום תוך-תאי של חלבונים באמצעות זיהוי

מוטיבים ברצף חומצות אמינו

יונתן גולן

**עבודה זו מוגשת כעבודה בהיקף של 2 יח' כמילוי חלקי של
הדרישות לקראת קבלת ציון במדע חישובי ביולוגיה (Biocode)**

עבודה זו בוצעה בהדרכת ורד קוניק

יוני 2026

תמצית:

בפרויקט זה פותחה תוכנית בשפת Python לחיזוי המיקום התוך-תאי של חלבונים באמצעות זיהוי motifs ברצף חומצות האמינו שלהם. התוכנית נבדקה על מאגר של 40 חלבונים ממאגר UniProt, ואת הביצועים שלה הערכתי באמצעות Accuracy, Precision, Recall ו-Confusion Matrix. תוצאות העבודה מראות כי ניתן לבצע חיזוי ראשוני ברמה סבירה של מיקום חלבונים באמצעות כללים ביולוגיים פשוטים.

תוכן עניינים:

מבוא	4-5
אנליזה ושיטה	6-10
תוצאות התוכנית	10-12
אישוש	13
דיון בתוצאות	14
סיכום	15
נספחים	16
ביבליוגרפיה	17

מבוא:

חלבונים הם מולקולות מרכזיות כמעט בכל תהליך המתרחש בתא. הם אחראים על מספר תפקידים, ביניהם זירוז תגובות כימיות, העברת אותות, בניית מבנים תאיים והובלת חומרים ממקום למקום. כדי שהחלבון יוכל לבצע את תפקידו בצורה תקינה, עליו להגיע למיקום המתאים בתוך התא. תהליך זה נקרא לוקליזציה תאית (Cellular Localization), והוא חיוני לפעילות התקינה של התא.

בתא קיימים מדורים תוך-תאיים שונים, ביניהם הגרעין, המיטוכונדריה, הרשתית האנדופלזמטית (ER), קרום התא והסביבה החוץ-תאית. לכל אחד מהמדורים יש תפקיד שונה, ולכן חלבונים שונים צריכים להגיע ליעדים שונים. מחקרים בתחום הביולוגיה התאית מראים שהתא משתמש במנגנוני מיון והכוונה כדי להעביר כל חלבון למקום שבו הוא אמור לפעול. כאשר מנגנון זה נפגע, החלבון עלול להגיע למיקום שגוי, מה שעלול לגרום לפגיעה בתפקוד התא ולגרום להתפתחות של מחלות.

אחד המנגנונים המרכזיים המאפשרים את הכוונת החלבונים הוא קיומם של מוטיבים (Motifs) או רצפי מטרה קצרים ברצף חומצות האמינו של החלבון. רצפים אלו משמשים כסוג של "כתובת" ביולוגית שאותה מזיהים מנגנוני ההובלה של התא. לדוגמה, Nuclear Localization Signal (NLS) מכון חלבונים אל גרעין התא. באופן דומה קיימים Signal Peptides המכוונים חלבונים למסלול ההפרשה או ל-ER, רצפי Mitochondrial Targeting Signal המכוונים חלבונים למיטוכונדריה, וגם מוטיב KDEL, שמסייע לשמור חלבוני ER בתוך הרשתית האנדופלזמטית במקרה שעברו בטעות למדור אחר. בנוסף קיימים אזורים הידרופוביים ארוכים היוצרים Transmembrane Helices, המאפיינים חלבוני ממברנה.

שאלת המחקר של פרויקט זה היא האם ניתן לחזות את המיקום התוך-תאי של חלבון באמצעות ניתוח רצף חומצות האמינו שלו בלבד. הקושי בפתרון זה הוא שלא כל החלבונים מכילים מוטיב ברור וחד משמעי, ולפעמים אותו motif יכול להופיע גם בחלבונים שמגיעים למדורים שונים. בנוסף, מיקום של חלבון מושפע גם מגורמים נוספים, כמו המבנה התלת ממדי שלו, אינטראקציות עם חלבונים אחרים ומנגנוני בקרה תאיים, שלא ניתנים לזיהוי מתוך הרצף בלבד. ולכן נדרש כלי חישובי המסוגל לעבור במהירות על מספר גדול של רצפים, לזהות בהם מאפיינים ביולוגיים ידועים מראש ולבצע חיזוי ראשוני של המיקום שלהם.

לצורך העבודה נעשה שימוש במאגר הנתונים UniProt, שהוא אחד ממאגרי המידע המרכזיים בתחום החלבונים. המאגר כולל מידע על רצפי חלבונים, תפקודם, המבנה שלהם, מיקומם בתא ומידע ביולוגי נוסף. הנתונים במאגר נאספים ממחקרים המתפרסמים בספרות המדעית, ומשולבים יחד עם מידע חישובי. במסגרת פרויקט זה נעשה שימוש ברשומות מתוך UniProt שעברו בדיקה ידנית על ידי

מומחים ולכן נחשב לאמין במיוחד. המידע על מיקום החלבונים מבוסס על שיטות ניסוי שונות, כגון מיקרוסקופיה פלואורסצנטית, סימון חלבונים, שיטות ביוכימיות ומחקרים מולקולריים נוספים.

לצורך המחקר נבחרו 40 חלבונים ממין השמר *Saccharomyces cerevisiae*. החלבונים חולקו לחמש קבוצות של מיקום תוך-תאי: גרעין, מיטוכונדריה, רשתית אנדופלזמטית, חלבוני ממברנה וחלבונים מופרשים, כאשר בכל קבוצה נבחרו שמונה חלבונים בעלי מיקום ידוע ומתועד. בחירה זו אפשרה לבדוק את יכולת החיזוי של התוכנית בצורה מאוזנת בין המדורים השונים.

בפריקט זה נכתבה תוכנית בשפת Python בסביבת העבודה Visual Studio Code. התוכנית קוראת רצפי חלבונים מקובץ FASTA, מזהה בהם motifs ביולוגיים שנבחרו מראש ומסווגת כל חלבון לאחד מחמשת המדורים התוך-תאיים שנבדקו. לאחר ביצוע החיזוי נערכה השוואה בין תוצאות התוכנית למידע הידוע ממאגר UniProt, והערכת ביצועי המודל בוצעה באמצעות המדדים Accuracy, Precision, Recall וגם Confusion Matrix. בפרקים הבאים יוצגו שיטת העבודה, האלגוריתם שפותח ותוצאות החיזוי שהתקבלו.

אנליזה ושיטה:

בניית מאגר הנתונים-

לצורך ביצוע המחקר נבנה מאגר נתונים המכיל 40 חלבונים ממין השמר *Saccharomyces cerevisiae*. החלבונים נבחרו ממאגר UniProt SwissProt, המכיל רשומות שעברו בדיקה ידנית ונחשבות לאמינות במיוחד.

החלבונים חולקו לחמש קבוצות על פי מיקומם התוך-תאי הידוע: גרעין (Nucleus), מיטוכונדריה (Mitochondria), רשתית אנדופלזמטית (ER), חלבוני ממברנה (Cell Membrane) וחלבונים מופרשים (Secreted). מכל קבוצה נבחרו שמונה חלבונים, כך שהתקבל מאגר מאוזן של 40 חלבונים בסך הכול.

רצפי החלבונים נשמרו בקובץ FASTA, שהוא פורמט נפוץ לאחסון רצפים ביולוגיים. כל רשומה בקובץ כוללת את שם החלבון ואת רצף חומצות האמינו שלו. בנוסף, נשמר עבור כל חלבון המיקום התוך-תאי הידוע מתוך מאגר UniProt לצורך השוואה לתוצאות החיזוי.

Protein	True Location	UniProt ID
RAP1_YEAST	Nucleus	P11938
RAD50_YEAST	Nucleus	P12753
RAD9_YEAST	Nucleus	P14737
SNF6_YEAST	Nucleus	P18888
MED15_YEAST	Nucleus	P19659
PRP4_YEAST	Nucleus	P20053
TAF13_YEAST	Nucleus	P11747
SPT2_YEAST	Nucleus	P06843
ODO1_YEAST	Mitochondria	P20967
CCPR_YEAST	Mitochondria	P00431
PREP_YEAST	Mitochondria	P32898
MTF1_YEAST	Mitochondria	P14908

ADH3_YEAST	Mitochondria	P07246
EFTU_YEAST	Mitochondria	P02992
ODPA_YEAST	Mitochondria	P16387
IDH2_YEAST	Mitochondria	P28241
BIP_YEAST	ER	P16474
PDI_YEAST	ER	P17967
EUG1_YEAST	ER	P32474
MPD1_YEAST	ER	Q12404
SIL1_YEAST	ER	Q08199
LHS1_YEAST	ER	P36016
MNL1_YEAST	ER	P38888
SCJ1_YEAST	ER	P25303
STE2_YEAST	Cell membrane	D6VTK4
CAN1_YEAST	Cell membrane	P04817
ITR1_YEAST	Cell membrane	P30605
MEP2_YEAST	Cell membrane	P41948
KCH1_YEAST	Cell membrane	P47114
BOR1_YEAST	Cell membrane	P53838
PDR12_YEAST	Cell membrane	Q02785
SHO1_YEAST	Cell membrane	P40073
SAG1_YEAST	Secreted	P20840
HS150_YEAST	Secreted	P32478
UTH1_YEAST	Secreted	P36135
PRY1_YEAST	Secreted	P47032
SUN4_YEAST	Secreted	P53616
PIR3_YEAST	Secreted	Q03180
PPA5_YEAST	Secreted	P00635
CHIT_YEAST	Secreted	P29029

בפרויקט הוגדרה מראש רשימה מצומצמת של motifs ביולוגיים ידועים, שנמצאו על פי מחקרים קשורים למיון חלבונים למדורים תוך-תאיים שונים. מטרת הבחירה ברשימה מוגדרת מראש הייתה לשמור על מודל פשוט וברור שניתן לנתח ולהעריך.

המוטיבים שנבדקו הם:

מוטיב שנבדק	מדור תוך-תאי
(Nuclear Localization Signal) NLS	גרעין
Mitochondrial Targeting Signal	מיטוכונדריה
KDEL, HDEL, RDEL	רשתית אנדופלזמטית
Signal Peptide	חלבונים מופרשים
Transmembrane Helix	חלבוני ממברנה

המוטיבים נבחרו על סמך ספרות ביולוגית המתארת את תפקידם בהכוונת חלבונים ליעדים שונים בתא.

האלגוריתם החישובי-

התוכנית פותחה בשפת Python ומבוססת על גישת Rule Based Classification. בגישה זו הסיווג מתבצע באמצעות כללים ביולוגיים ידועים ולא באמצעות למידת מכונה.

תחילה התוכנית קוראת את קובץ ה-FASTA ומחלצת מכל רשומה את שם החלבון ואת רצף חומצות האמינו שלו. לאחר מכן מופעלות מספר פונקציות שמטרתן לזהות motifs שונים ברצף.

לאחר זיהוי המוטיבים, התוכנית מפעילה סדרת כללים קבועה לצורך קביעת המיקום הסופי של החלבון. סדר הבדיקה הוא:

1. בדיקת מוטיב ER retention.
2. בדיקת mitochondrial targeting signal.

3. בדיקת Nuclear Localization Signal.

4. בדיקת Signal Peptide.

5. בדיקת Transmembrane Helix.

כאשר נמצא motif מתאים, החלבון מסווג למדור המתאים והתהליך נעצר. שיטה זו מאפשרת להכריע גם במקרים שבהם חלבון מכיל יותר ממאפיין אחד.

הפונקציות המרכזיות בתוכנית-

התוכנית מורכבת ממספר פונקציות שכל אחת מהן אחראית לזיהוי motif ביולוגי מסוים.

הפונקציה has_signal_peptide בודקת את 30 חומצות האמינו הראשונות ברצף ומחשבת כמה מהן הידרופוביות. אם מספרן עובר סף שנקבע מראש, מזוהה Signal Peptide.

הפונקציה has_er_retention בודקת האם רצף החלבון מסתיים באחד מהמוטיבים KDEL, HDEL או RDEL, הידועים כמוטיבי שמירה של חלבוני ER.

הפונקציה has_nls מחפשת חלונות של חמש חומצות אמינו ומזהה אזורים עשירים בחומצות אמינו בסיסיות, המאפיינים Nuclear Localization Signals.

הפונקציה has_mito_signal בודקת את תחילת הרצף ומחפשת ריכוז גבוה של חומצות אמינו חיוביות, המאפיינות mitochondrial targeting signals.

הפונקציה has_transmembrane_helix סורקת את רצף החלבון ומחפשת מקטעים ארוכים ועשירים בחומצות אמינו הידרופוביות, המאפיינים אזורים חוצי ממברנה.

לבסוף, הפונקציה predict_location משלבת את כל הבדיקות ומחזירה את המיקום התוך-תאי החזוי.

גורמי שגיאה ומגבלות השיטה-

למרות שהתוכנית מבוססת על motifs ביולוגיים ידועים, קיימים מספר גורמים העלולים לגרום לשגיאות בחיזוי:

ראשית, לא כל החלבונים מכילים motif ברור וחד משמעי. במקרים כאלה קשה לקבוע את המיקום התוך-תאי על סמך הרצף בלבד.

בנוסף, חלק מהמוטיבים דומים זה לזה או מופיעים במקרה גם בחלבונים שאינם שייכים למדור שאליו הם בדרך כלל מקושרים. מצב זה עלול לגרום לסיווג שגוי.

מגבלה נוספת היא שהמודל מתבסס אך ורק על רצף חומצות האמינו ואינו מתחשב בגורמים ביולוגיים נוספים כגון מבנה תלת ממדי של החלבון, אינטראקציות עם חלבונים אחרים או מנגנוני בקרה תאיים.

לבסוף, מאגר הנתונים כלל 40 חלבונים בלבד. למרות שמספר זה מספיק לצורך הערכת המודל במסגרת הפרויקט, מאגר גדול יותר היה מאפשר לקבל הערכה מדויקת יותר של ביצועי החיזוי.

תוצאות התוכנית:

מטרת התוכנית הייתה לחזות את המיקום התוך-תאי של חלבונים על סמך זיהוי motifs ברצף חומצות האמינו שלהם. לצורך הבדיקה הורצה התוכנית על מאגר של 40 חלבונים שמיקומם התוך-תאי ידוע מראש.

עבור כל חלבון הושווה המיקום שחזתה התוכנית למיקום הידוע מתוך מאגר UniProt. התוצאות נשמרו בטבלת ולידציה שכללה את שם החלבון, המיקום הידוע, המיקום החזוי והאם החיזוי היה נכון.

Accuracy כולל-

מתוך 40 חלבונים שנבדקו, 29 סווגו בצורה נכונה.

לכן התקבל:

$$\text{Accuracy} = 29 / 40 = 0.725$$

כלומר, התוכנית הצליחה לחזות נכון את המיקום התוך-תאי של כ-72.5% מהחלבונים שנבדקו.

Precision ו-Recall עבור כל מדור תוך-תאי-

לצורך הערכה מפורטת יותר של ביצועי המודל חושבו מדדי Precision ו-Recall עבור כל אחד מחמשת המדורים התוך-תאיים. ניתן לראות כי הערכים הגבוהים ביותר של Precision התקבלו עבור חלבוני ER, בעוד שערך ה-Recall הנמוך ביותר התקבל עבור חלבוני גרעין.

מיקום תוך-תאי	Precision	Recall
Nucleus	0.75	0.375
Mitochondria	0.538	0.875
ER	1	0.875
Cell Membrane	0.833	0.625
Secreted	0.7	0.875

-Confusion Matrix

לצורך הצגת התפלגות השגיאות נבנתה Confusion Matrix המציגה עבור כל מיקום ידוע את הסיווג שחזתה התוכנית.

Secreted	Cell	ER	Mito	Nucleus	True \ Predicted
1	1	0	3	3	Nucleus
1	0	0	7	0	Mitochondria
1	0	7	0	0	ER
0	5	0	2	1	Cell Membrane
7	0	0	1	0	Secreted

הערכים באלכסון הראשי מייצגים חיזויים נכונים, ואילו הערכים שמחוץ לאלכסון מייצגים שגיאות סיווג.

דוגמאות לחיזויים נכונים-

התוכנית הצליחה לסווג בצורה נכונה מספר רב של חלבונים.

דוגמאות:

חלבון	מיקום ידוע	מיקום חזוי
BIP_YEAST	ER	ER
PDI_YEAST	ER	ER
CCPR_YEAST	Mitochondria	Mitochondria
SAG1_YEAST	Secreted	Secreted
STE2_YEAST	Cell Membrane	Cell Membrane


דוגמאות לחיזויים שגויים-

בנוסף קרו מספר מקרים שבהם המודל ביצע סיווג שגוי:

חלבון	מיקום ידוע	מיקום חזוי
RAP1_YEAST	Nucleus	Secreted
TAF13_YEAST	Nucleus	Mitochondria
RAD50_YEAST	Nucleus	Cell Membrane
UTH1_YEAST	Secreted	Mitochondria
KCH1_YEAST	Cell Membrane	Mitochondria

גרף ביצועי Recall-

בנוסף לטבלאות, נוצר גרף עמודות המציג את ערכי ה-Recall עבור כל אחד מהמדורים התוך-תאיים שנבדקו.



אישוש:

בפרויקט זה בוצע אישוש לתוכנית באמצעות השוואת תוצאות החיזוי של המודל למידע הביולוגי הידוע ממאגר UniProt. מכיוון שכל החלבונים שנבחרו למחקר הם חלבונים בעלי מיקום תוך-תאי מתועד, היה ניתן לבדוק עבור כל חלבון האם המיקום שחזתה התוכנית תואם למיקום האמיתי.

לצורך האישוש בניתי טבלת ולידציה שבה עבור כל אחד מ-40 החלבונים הופיעו שם החלבון, המיקום הידוע, המיקום שחזתה התוכנית והאם החיזוי היה נכון. ההשוואה ביניהם אפשרה לבדוק באופן ישיר את ביצועי האלגוריתם עבור כל מיקום.

בנוסף חושבו מדדי Accuracy, Precision ו-Recall, וגם נבנתה טבלת Confusion Matrix המתארת את התפלגות החיזויים הנכונים והשגויים בין המדורים התוך-תאיים השונים. תוצאות האישוש הראו כי מתוך 40 חלבונים שנבדקו, 29 סווגו בצורה נכונה, ולכן התקבל Accuracy של 72.5%.

מדדי Precision ו-Recall אפשרו לבחון את איכות החיזוי עבור כל אחד מהמדורים התוך-תאיים בנפרד. נמצא כי חלבוני ER זוהו בצורה מדויקת במיוחד, בעוד שחלבוני גרעין היו הקבוצה שבה שיעור החיזויים הנכונים היה הנמוך ביותר.

תוצאות האישוש מוכיחות שהתוכנית אכן מצליחה לזהות חלק גדול מהמיקומים התוך-תאיים באמצעות motifs בלבד, אך במקרים מסוימים קיימות טעויות סיווג הנובעות מהמגבלות הביולוגיות של השיטה ומהעובדה שלא כל החלבונים מכילים motifs חד משמעיים.

דיון בתוצאות:

מטרת העבודה הייתה לבדוק האם ניתן לחזות את המיקום התוך-תאי של חלבון באמצעות זיהוי motifs ברצף חומצות האמינו בלבד.

תוצאות התוכנית מראות כי ניתן לבצע חיזוי ברמת דיוק סבירה. המודל הצליח לסווג נכון 29 מתוך 40 חלבונים, כלומר Accuracy של 72.5%.

ניתן בנוסף לראות כי ביצועי המודל אינם זהים עבור כל המדורים התוך-תאיים. חלבוני ER קיבלו את ערך ה-Precision הגבוה ביותר (1.0), ככל הנראה משום שמוטיב KDEL הוא מוטיב ייחודי יחסית ולכן קשה להתבלבל בינו לבין רצפים אחרים.

גם חלבוני המיטוכונדריה והחלבונים המופרשים קיבלו ערכי Recall גבוהים יחסית, דבר המעיד שהתוכנית הצליחה לזהות את רוב החלבונים השייכים לקבוצות אלו.

לעומת זאת, חלבוני הגרעין קיבלו Recall נמוך יחסית. ככל הנראה הסיבה לכך היא שמוטיבי NLS מגוונים מאוד ואין להם תמיד רצף קבוע וברור, ולכן הכללים הפשוטים שנבחרו בפרויקט אינם מצליחים לזהות את כל המקרים.

בנוסף, היו מספר חלבונים שסווגו בטעות למיטוכונדריה או למסלול ההפרשה, כנראה מכיוון שהרצף שלהם הכיל מאפיינים שדומים למוטיבים שנבדקו למרות שמיקומם האמיתי שונה.

אחת המגבלות המרכזיות של העבודה היא שהמודל מבוסס אך ורק על רצף חומצות האמינו. בפועל, מיקום של חלבון בתא מושפע גם מהמבנה התלת ממדי שלו, מאינטראקציות עם חלבונים אחרים ומנגנוני בקרה נוספים שלא לקחתי בחשבון.

בנוסף, המודל מבוסס על מספר קטן יחסית של motifs ידועים ועל מאגר של 40 חלבונים בלבד. הרחבת מאגר הנתונים והוספת motifs נוספים יכלו לשפר את ביצועי החיזוי.

למרות המגבלות האלה, התוצאות מראות כי גם מודל פשוט המבוסס על כללים ביולוגיים יכול להצליח בחיזוי של מיקום תוך-תאי עבור חלק משמעותי מהחלבונים.

סיכום:

בפרויקט זה נבדקה האפשרות לחזות את המיקום התוך-תאי של חלבונים באמצעות זיהוי motifs ברצף חומצות האמינו בלבד.

לשם כך פותחה תוכנית בשפת Python. התוכנית קוראת רצפי חלבונים מקובץ FASTA, מזהה מספר motifs ביולוגיים ידועים ומסווגת כל חלבון לאחד מחמישה מדורים תוך-תאיים.

לאחר ביצוע ולידציה על מאגר של 40 חלבונים התקבל Accuracy של 72.5%, דבר המראה כי ניתן לבצע חיזוי ראשוני ופשוט באמצעות כללים ביולוגיים פשוטים.

תוצאות אלו תואמות באופן כללי את הידוע בספרות, שעל פיו חיזוי המבוסס על רצף חומצות האמינו בלבד מסוגל לספק הערכה ראשונית של מיקום החלבון, אך אינו מגיע לרמת הדיוק של שיטות מתקדמות יותר המשלבות מידע מבני ואלגוריתמים של למידת מכונה.

במהלך העבודה העמקתי את ההבנה שלי בנושא מיון חלבונים בתא, למדתי כיצד להשתמש במאגרי מידע ביולוגיים כמו UniProt, וכיצד ניתן לשלב ידע ביולוגי עם תכנות לצורך פתרון בעיה מחקרית.

בעתיד ניתן יהיה לשפר את המודל באמצעות שימוש במספר גדול יותר של חלבונים, הוספת motifs נוספים או שילוב שיטות מתקדמות יותר, כמו אלגוריתמים של למידת מכונה.

נספח א - הוראות הרצה:

לצורך ההרצה יש לוודא שקובץ הקוד הראשי וקובץ ה-FASTA נמצאים באותה תיקייה.


לאחר פתיחת הקובץ הראשי ניתן להריץ את התוכנית. בסיום ההרצה יודפסו למסך תוצאות החיזוי וגם יחושבו מדדי Accuracy, Precision, Recall ו-Confusion Matrix.

נספח ב – שינוי פרמטרים:

ניתן לשנות את קובץ ה-FASTA המכיל את רצפי החלבונים לצורך בדיקה של מאגרי נתונים אחרים.

בנוסף ניתן לשנות את הערכים של הפונקציות המזהות את המוטיבים הביולוגיים, ובכך לבחון איך שינויים אלו משפיעים על ביצועי החיזוי.

נספח ג:



ביבליוגרפיה (סקירת ספרות):

<https://www.uniprot.org/>

<https://www.khanacademy.org/science/biology/gene-expression-central-dogma/translation-polypeptides/a/protein-targeting-and-traffic>

<https://www.sciencedirect.com/science/article/pii/S0960982295000339>

[https://bio.libretexts.org/Bookshelves/Cell_and_Molecular_Biology/Biofundamentals_2e_\(Klymkowsky_and_Cooper\)/10%3A_Social_Systems/10.01%3A_Targeting_membrane_proteins_to_where_they_need_to_be#title](https://bio.libretexts.org/Bookshelves/Cell_and_Molecular_Biology/Biofundamentals_2e_(Klymkowsky_and_Cooper)/10%3A_Social_Systems/10.01%3A_Targeting_membrane_proteins_to_where_they_need_to_be#title)